

# Optimización genética aplicada a la planificación de inversiones de generación eléctrica.

Msc. Ing. Ruben Chaer, *Member IEEE*, and Dr. Ing Gonzalo Casaravilla, *Senior Member IEEE*.

**Resumen-** El continuo crecimiento de la demanda eléctrica trae aparejado la necesidad de acompañar dicho crecimiento con la instalación de nuevas centrales de generación. El diseño de un plan de expansión óptimo es un problema complejo por los montos de inversiones involucrados y porque los plazos de construcción de nuevas centrales van de 2 a 8 años dependiendo de la tecnología. Esto hace que la decisión del plan involucre un riesgo alto asociado a las hipótesis que se asuma sobre el futuro. En este trabajo se muestra un algoritmo genético aplicado a la optimización del plan de inversiones. El objetivo es mostrar un método y explorar su potencial con miras a la investigación de mejores métodos a sabiendas que el algoritmo implementado es seguramente mejorable.

**Index Terms--** Distributed algorithms, Genetic algorithms, Power system optimization, Power system planning, Power system simulation..

## I. INTRODUCCIÓN

Este trabajo muestra una primer implementación de un Algoritmo Genético (GA) para la optimización de las inversiones de generación.

El continuo crecimiento de la demanda de energía eléctrica y el envejecimiento del parque de generación existente, lleva a que continuamente haya que estar instalando nuevas centrales de generación para cubrir la demanda al menor costo posible y con un criterio de calidad aceptable.

La planificación de las inversiones en generación de energía eléctrica implica tomar decisiones en cuanto al tipo de tecnologías a utilizar (turbinas de vapor, turbinas de gasoil, ciclos combinados, etc.) del tipo de combustibles (renovables, fósiles, nuclear) y determinar con precisión las fechas de incorporación de los proyectos.

La construcción de una nueva central de generación lleva entre 2 y 10 años dependiendo del tipo de central y de la necesidad de infraestructura adicional (puertos por ejemplo) o de desarrollo de las capacidades nacionales de gestión de una nueva tecnología como es el caso de la núcleo-eléctrica.

Estos plazos de construcción lleva a que la decisión de “qué instalar y cuándo”, tenga que ser tomada con años de anticipación y considerando un horizonte de tiempo del orden de 20 a

50 años hacia el futuro que permita evaluar el desempeño de los posibles planes de inversión.

Esto trae un problema al que toma las decisiones dado que necesariamente la decisión se debe tomar con lo que se supone será el futuro y por consiguiente quién toma la decisión está irremediabilmente expuesto a ser criticado pues seguramente el futuro se comportará diferente a lo supuesto.

Las principales incertidumbres son: cuál será el crecimiento real de la demanda (por ejemplo al día de hoy, no se sabe con certeza el efecto sobre la demanda eléctrica de la conversión del transporte automotriz a eléctrico y de la sustitución de los calentadores de agua eléctricos por solares), cuál será la disponibilidad y precio de los combustibles fósiles en el futuro (petróleo, gas, carbón) y cuál será la variación de los costos de inversión de las diferentes tecnologías. Otro factor de incertidumbre importante es nuestra capacidad de realizar las inversiones en el tiempo planificado. Este factor no es menor sobre todo por las trabas burocráticas con el agregado cada vez más importante de las exigencias ambientales (que aumentan la carga burocrática) y la resistencia creciente de la población a que le instalen cualquier proyecto de gran porte en su vecindad.

Dado el conjunto de tecnologías y los escenarios futuros de crecimiento de la demanda, precios de combustibles y tecnologías, encontrar el Plan de Inversiones de Óptimo, implica buscar las combinaciones de proyectos que lleven al menor Costo de Abastecimiento de la Demanda (CAD) calculado como el total de costos variables e inversiones desde ahora al final de los tiempos.

Está claro que dado el conjunto de incertidumbres manejadas y de las aleatoriedades inherentes a nuestro sistema de generación (aportes hidráulicos a las represas, velocidad del viento, radiación solar y disponibilidad de las máquinas e interconexiones), el CAD asociado a un Plan de Inversiones (PI) más que un valor, es una distribución de valores resultados de la simulación de muchos escenarios posibles del futuro.

En este trabajo, se utilizó la plataforma de Simulación de sistemas de Energía Eléctrica - SimSEE [1] para calcular el CAD dado un PI. Como medida de la distribución del CAD se calcularon dos valores CAD y CADr5 que son respectivamente el valor esperado de la distribución y el valor con riesgo de 5% de ser excedido.

La búsqueda del plan óptimo se realiza minimizando el CAD y se registra el CADr5 para tener una medida del riesgo de sobre costo de cada plan evaluado.

R. Chaer. Es Prof. Adjunto del Departamento de Potencia del Instituto de Ingeniería Eléctrica - Montevideo - Uruguay. (e-mail: rchaer@fing.edu.uy).

G. Casaravilla. Es Prof. Del Departamento de Potencia del Instituto de Ingeniería Eléctrica y Presidente de la empresa UTE - Montevideo - Uruguay (e-mail: gcp@fing.edu.uy).

Formalmente el planteo de búsqueda del plan óptimo sería:

$$\min_{PI} \{CAD(PI)\} \quad (ec.1) \\ PI \in D$$

Para la aplicación de la un Algoritmo Genético a la resolución de este problema, definiremos como “individuos” a cada posible PI y como medida de desempeño del individuo el valor - CAD (menos el CAD) de dicho PI. Dados dos individuos PI<sub>x</sub> y PI<sub>y</sub>, diremos que PI<sub>x</sub> es más exitoso, o que se adapta mejor, que PI<sub>y</sub> si CAD( PI<sub>x</sub> ) < CAD( PI<sub>y</sub> )

Definida una forma de identificar los posibles individuos (puntos PI de D en nuestro caso) y definida la función de éxito (-CADve en nuestro caso), un algoritmo genético en forma genérica consiste en crear un conjunto de individuos G[i] que llamaremos “Generación i”, evaluar todos los individuos de la G[i], permitir que los “mejores” (los de mayor - CAD) se apareen entre ellos para generar la nueva generación G[i+1] y así en forma repetida con la esperanza de que las nuevas generaciones vayan superando a las anteriores. Durante el apareamiento, los PI mezclan su información (cruzamiento) y adicionalmente se puede incorporar nueva información por alteraciones al azar del resultado del cruzamiento, lo que se conoce como “mutación” en la terminología genética.

Cuál es la descripción del PI (o sea cómo describimos su información genética, aquello que lo diferencia de los demás) y cómo se mezcla la genética de dos PI para crear un nuevo PI es parte fundamental del proceso y por supuesto que no existe una única solución. Que el algoritmo “busque el óptimo” es que de alguna forma quienes tiene mayor éxito tengás mayor posibilidad de dejar descendencia.

Para la ejecución del trabajo se implementó el algoritmo en el equipo de cálculo de alto desempeño de FING [2] usando un total de 132 nodos de calculo para calcular una población de un total de 404034 individuos. A los efectos de dar una idea el costo nominal por el servicio de uso de este equipamiento para realizar dicho cálculo fue de aproximadamente USD 350.

En lo que sigue se expone una descripción sencilla de los algoritmos genéticos, de la construcción muy sencilla del problema que se realizó y se muestran los resultados obtenidos en la aplicación del algoritmo para la planificación de las inversiones de generación en un horizonte de 2009-2026.

## II. SELECCIÓN NATURAL.

Darwin en 1859 estableció el principio de “*selección natural*” de la siguiente forma: “*En lucha por la vida, las variaciones, por insignificante que fueran, si son en algún grado provechosas para los individuos de una especie, en sus relaciones infinitamente complejas con otros los seres orgánicos y con sus condiciones físicas de vida, tenderán a la preservación de tales individuos y generalmente serán heredadas por la descendencia. Las crías, también, tendrán una mejor opor-*

*tunidad de sobrevivir, ya que, de los muchos individuos de una especie que periódicamente nacen, sólo un pequeño número puede sobrevivir.*”.

Este es el principio rector de los algoritmos genéticos, intentar que aquello que hizo a un individuo más apto que los demás de alguna forma le de mayor probabilidad de trascender por medio de su descendencia.

Los algoritmos genéticos y evolutivos fueron introducidos por Holland (1975) y Rechenberg (1973). Imitando los principios básicos de la naturaleza ellos crearon algoritmos de optimización que se han aplicado con éxito a una variedad de problemas.

A los efectos de implementar un algoritmo genético hay que lograr una representación del problema en que cada posible solución sea codificada como si fuera un “individuo” de una especie. La codificación de aquello que distingue a un individuo de otro debe realizarse de forma tal que sea posible crear nuevos individuos “cruzando” dos individuos dados. Para dejar jugar el azar y que puedan aparecer variaciones que no sean exactamente el resultado de mezclar la información de dos progenitores por la operación de cruzamiento es necesario también implementar la posibilidad de introducir ruido en la codificación, operación que corresponde en la naturaleza al fenómeno denominado “mutación”.

Al paquete de información que distingue un individuo de otro y codificado de forma tal que es posible definir operaciones de “cruzamiento” y “mutación” es lo que llamaremos el Genotipo de un individuo. Dado un Genotipo, mediante una decodificación adecuada podemos obtener aquellas características del individuo que lo hacen más o menos apto para sobrevivir. (por ejemplo su velocidad, ferocidad, etc.).

Llamaremos  $fg(G)$  a la función que dado un genotipo nos permite obtener el Fenotipo del individuo. Dado el Fenotipo de un individuo es necesario tener la forma de evaluar su aptitud para sobrevivir y para ello hay que disponer de una función de aptitud o de éxito. Esta función de aptitud, nos permite ordenar a los individuos de una generación por su capacidad de adaptación y supervivencia. A los efectos de crear los individuos de la próxima generación basta con permitir que el apareamiento entre los más aptos tenga más probabilidad que entre los menos aptos para dar la señal necesaria para que actúe “la selección natural” de Darwin. La implementación del un algoritmo genético implica una elección de una forma de codificación de los genotipos, su traducción a los fenotipos y la capacidad de evaluar la aptitud de un individuo en base a su fenotipo. A nivel de los genotipos también es necesario definir las operaciones de cruzamiento y mutación. También hay que definir el mecanismo de asignación de probabilidades de generar descendencia en base a la aptitud de los individuos.

En el libro “Representations for Genetic and Evolutionary Algorithms” [3] puede verse una buena descripción de la representación de algoritmos genéticos con una definición más precisa de Genotipo, Fenotipo y función de Aptitud o adaptabilidad.

Adicionalmente a los conceptos genéticos ya mencionados, en la naturaleza, dos gemelos, con la misma composición genética pueden correr en su vida con suertes diferentes. En la implementación realizada esto también se modeló. En este

sentido, será que un mismo genotipo puede ser evaluado con diferentes “suertes” entendiendo por tal la realización de un determinado conjunto de procesos estocásticos que afectan el resultado de la función de aptitud del individuo. De esa forma, puede ocurrir que un Genotipo dado implique un individuo con un alto grado de aptitud y que por lo tanto con mayor probabilidad que los menos aptos sea seleccionado para dejar descendencia, pero perfectamente puede ocurrir que el alto grado de aptitud se debió a “la suerte” que le tocó vivir a ese individuo, de esa forma cuando su genética se propague, las futuras generaciones no recibirán seguramente una calificación tan alta desapareciendo a la larga la descendencia que por la suerte corrida por un individuo logró propagarse. En la implementación más clásica de un algoritmo genético se crean generaciones de individuos en un bucle que se inicia con una generación creada al azar. Cada individuo de la generación activa es entonces evaluado creando así un orden de aptitud en la generación. Luego, con cierto criterio que privilegia el apareamiento de los más aptos. Se seleccionan pares de individuos que dan lugar a nuevos individuos por aplicación de las operaciones de “cruzamiento” y “mutación” sobre los padres. En el algoritmo presentado en este trabajo, se optó por una variación de este mecanismo clásico y en lugar de tener una generación activa, se mantiene vivo a todo individuo que alguna vez fue evaluado. De esta forma, si mediante un cruzamiento se vuelve a generar el mismo individuo, volverá a ser evaluado, pero seguramente con otra suerte y se tiene así más información sobre esa genética. En la medida en que avanza el algoritmo, las genéticas más exitosas tendrán mayor número de suertes evaluadas y por consiguiente se va reforzando que realmente corresponden a una genética ganadora y no a una suerte circunstancial.

A continuación se describe la representación genética adoptada definiendo la implementación utilizada para la codificación de la genética en Genotipos y las operaciones de Cruzamiento y Mutación y la forma en que se privilegia el apareamiento de los más aptos.

#### A. Genotipo

En forma sencilla, la información que hace único a un individuo la supondremos codificada en un paquete que llamaremos Genotipo. Hay muchas formas de codificar el genotipo, por ejemplo binaria en cadenas de ceros y unos, o como cadenas de números enteros o reales, o caracteres de algún otro alfabeto. Es importante la codificación que se elija, pues es a ese nivel que se deben definir las operaciones de “cruzamiento” y “mutación”. El ejemplo más sencillo y usado es la codificación binaria.

En este trabajo el Genotipo de un PI es un vector de 38 números enteros. Los primeros 19 indican para cada año de 2008 a 2026 la cantidad de Parques eólicos de 20 MW que se plantea instalar en cada uno de esos años y los segundos 19 indican la cantidad de centrales térmicas de 180 MW que se pretenden instalar en cada año de 2008 a 2026. Por cómo es el sistema Uruguayo el óptimo para la entrada en operación de los proyectos es antes del Invierno. Por esta razón basta con saber el año de entrada. Si fuera necesario optimizar el mes de entrada

también, los Genotipos serían de largo 38x12.

En la generación de nuevos individuos PI, existen ciertas restricciones. Por ejemplo, no es técnicamente posible incorporar parques eólicos antes del año 2013, ni nuevas centrales de generación antes del 2014, con lo cual los individuos con valores  $> 0$  en sus genotipos en las zonas correspondientes a los años 2008-2012 para las incorporaciones eólicas o en los años 2008-2013 para las incorporaciones térmicas no son individuos viables y serán descartados sin ser evaluados.

#### B. Cruzamiento

La operación de cruzamiento utilizada consiste en mezclar los Genotipos de los dos progenitores copiando casillero a casillero el valor de uno de los dos seleccionado al azar con igual probabilidad.

El pseudo-código Pascal sería:

```
function Cruzar( Papá, Mamá: TGenotipo ): TGenotipo;
var
  k: integer;
  Bebé: TGenotipo;
begin
  for k:= low( Papá ) to high( Papá ) do
    if ( random < 0.5 ) then
      Bebé[k]:= Papá[k]
    else
      Bebé[k]:= Mamá[k];
  result:= Bebé;
end;
```

Está claro que esta forma de cruzamiento puede no ser la mejor. En este trabajo se implementó esta forma de cruzamiento como una primer aproximación y para construir un algoritmo que se pueda usar de base para investigar mejores funciones de cruzamiento.

#### C. Mutación

La operación de mutación se implementó seleccionando un casillero al azar del Genotipo (en las zonas viables) y con probabilidad 50% se suma un número entero aleatorio entre 1 y 10 y con probabilidad 50% se resta un número aleatorio entre 1 y 10. Si al realizar la resta el número resulta negativo se impone un 0 (cero).

El pseudo-código Pascal de esta operación sería:

```
procedure Mutar( var Individuo: TGenotipo );
var
  k: integer;
begin
  // seleccionamos un casillero al azar.
  k:= random( low(Individuo), high( Individuo ));
  if (random > 0.5 ) then
    // con probabilidad 50% incrementamos el casillero
    Individuo[k]:= Individuo[k] + random( 0, 10)
  else
    // con probabilidad 50% decrementamos
    Individuo[k]:= max( 0, Individuo[k] - random( 0, 10));
end;
```

Una vez obtenido el genotipo aplicando la operación de cruzamiento sobre los genotipos de los progenitores, con pro-

babilidad 70% se aplica el procedimiento de mutación y con probabilidad 30% no se aplica. Esta probabilidad es un parámetro de ajuste y seguramente dependerá del tipo de problema cuál será el mejor valor para lograr una convergencia adecuada. Cuanto menor sea la probabilidad de mutación menor será la probabilidad de innovar la genética lo que significa que menor será la probabilidad de encontrar nuevas soluciones. Con una probabilidad de mutación muy baja se corre el riesgo de no explorar todo el espacio de búsqueda y por consiguiente converger a un óptimo local. Por otra parte una probabilidad de mutación muy alta hará más difícil la convergencia al óptimo por el ruido inyectado por la genética.

#### D. Selección Natural

El mecanismo de Selección Natural, es aquel por el que los más aptos tienen mayor probabilidad de sobrevivir y dejar descendencia. En nuestra implementación este privilegio de los más aptos se logra al seleccionar los progenitores para crear un nuevo individuo. Cada vez que se va a crear un nuevo individuo, se obtienen dos progenitores ( Papá y Mamá ) que se seleccionan mediante el siguiente algoritmo:

Sea  $N$  es la cantidad de Genomas evaluados hasta el momento. Para cada uno tenemos el valor esperado de su Función de Aptitud (estimado como el promedio de los valores obtenidos en el conjunto de evaluaciones que hayan ocurrido para ese genotipo). Si tenemos la lista de todos los genotipos ordenados por orden decreciente de su Aptitud se trata de definir un mecanismo que asigne mayor probabilidad a los primeros de la lista.

En nuestro caso el algoritmo es:




Fig.1. Selección de un progenitor.

La variable “ $k$ ” se inicializa apuntando al más exitoso ( $k=0$ ). Luego, se realiza un sorteo uniforme entre  $[0, 1]$  y con probabilidad  $p_\alpha$  y mientras queden individuos menos exitosos se incrementa la variable “ $k$ ”.

El más exitoso de los genomas es entonces seleccionado con probabilidad  $(1 - p_\alpha)$  y con probabilidad  $p_\alpha$  no será seleccionado y por consiguiente será seleccionado algún genoma menos exitoso. El mismo juego de probabilidades se aplica a la lista de los menos exitosos dado que no se seleccionó el primero. Es sencillo extender el razonamiento y verificar que

el elemento “ $k$ ” de la lista es seleccionado con una probabilidad:

$$P(k) = p_\alpha^k \cdot (1 - p_\alpha) ; k = 0, 1, \dots, N-1 \quad (\text{ec.2}).$$

Dado que  $p_\alpha < 1$  el término  $p_\alpha^k$  decae exponencialmente lográndose así privilegiar el cruzamiento de los más exitosos.

Tal como está el diagrama de bloques de la fig. 1 el genotipo menos exitoso tiene el beneficio de acumular el residuo de las probabilidades cuando el algoritmo sale por llegar a  $k=N-1$ .

Este residuo tiene el valor  $p_\alpha^N$  por lo que ese “privilegio” es rápidamente despreciable al crecer la cantidad de genotipos evaluados  $N$ .

En los resultados presentados en este trabajo se utilizó

$p_\alpha = 0.93$ . Este es un parámetro del método que seguramente sea conveniente calibrar según el tipo de problema.

#### E. Fenotipo

El Fenotipo, es el conjunto de características del individuo que surgen de su Genotipo. El Fenotipo por tanto es un mapeo del Genotipo que describe las características del individuo y que determinan su aptitud para sobrevivir. Este mapeo no tiene por que ser biunívoco, puede haber más de un genotipo que conduzcan al mismo fenotipo y por lo tanto generen dos individuos igualmente aptos. También podría ocurrir que si se está evaluando sobre un mundo cambiante, dos individuos que son igualmente aptos para un momento histórico del mundo en el que están compitiendo, puedan no resultar igualmente aptos si el mundo cambiara. En nuestro caso el Fenotipo está formado por un vector con el total de eólica incorporada año a año, el total de centrales térmicas incorporados año a año y la información de costos tanto de inversiones como costos variables que dichas incorporaciones implican. Dado un Genotipo, dicha información es usada para generar un archivo de simulación SimSEE que es la que contiene el Fenotipo. La decodificación del genotipo se realiza por tanto al crear el archivo de simulación SimSEE y es una operación sencilla.

#### F. Función de Aptitud.

Se implementó una función de Aptitud como menos el Costo de Abastecimiento de la Demanda (-CAD) considerando para el cálculo del CAD tanto los costos fijos de las nuevas inversiones como los costos variables de generación. Los costos variables de generación lo forman los gastos en Gasoil, Fueloil, Gas Natural, importación, pagos de energía a los generadores eólicos y generación con biomasa y costos de falla. También se sumó al CAD el valor de la función de Costo Futuro del estado al que termina la simulación de SimSEE, para reflejar el costo esperado de la operación futura de acuerdo al estado en que cada individuo deja el sistema (entre dos individuos que gasten lo mismo en el horizonte de tiempo simulado se considera más exitoso al que deje más recursos almacena-

dos para el futuro). El CAD es el valor actual de los diferentes costos (expresados en dólares de enero de 2010) actualizados al 12% anual real.

Para representar la volatilidad de los costos variables, asociada a la volatilidad del costo de los combustibles fósiles, se utilizó en SimSEE, al igual que para la representación de los aportes hidráulicos a las represas, un sintetizador CEGH (ver apéndice de [4]). Este sintetizador se utiliza para producir series sintéticas del precio del barril de petróleo, ajustado con la proyección de la EIA [5] de forma de lograr que los escenarios de mínima y de máxima definan un cono en el que los precios del barril de petróleo estará con 90% de confianza como se muestra la fig. 2.




Fig. 2 Proyección del precio del petróleo.

En las simulaciones realizadas se indexó el precio del Gas Natural, del Fueloil, del Gasoil y los costos de falla del sistema directamente con el precio del barril de petróleo.

Otras fuentes de aleatoriedad son los aportes hidráulicos, la producción de los parques eólicos y la disponibilidad de las centrales de generación. En cada simulación (evaluación de un genotipo) se simuló 100 crónicas sintéticas de aportes hidráulicos, disponibilidad y precio de petróleo. Para la producción de los parques eólicos se utilizó el modelo presentado en [6].

Como resultado de la simulación se obtienen entonces 100 valores del CAD, uno para cada crónica. Para definir un único número para la función de aptitud se decidió utilizar el valor esperado y como mejor estimación del mismo, se utiliza el promedio de los 100 valores. Así cuando decimos el CAD estamos refiriéndonos al promedio de los 100 valores. Para tener una idea de la dispersión del resultado se almacena también el valor CADr5, que corresponde al valor que es excedido con un riesgo de 5%. Esto nos permite definir una función de aptitud que tenga en cuenta la aversión al riesgo mediante una combinación lineal convexa del CAD y CADr5. En los resultados presentados en este trabajo se consideró cero aversión al riesgo y por tanto la función de aptitud solamente considera el CAD.

El CAD está calculado como los montos de los años 2009 a 2026, actualizados al 12% a inicio de 2009. Por lo tanto cuando se observen los valores del CADr5 téngase en cuenta que el valor (CADr5- CAD) es una medida de la desviación estándar de la suma de 18 años actualizados al 12% por lo que la volatilidad está amortiguada por el promedio de los 18 años.

#### G. Suerte.

Además de los procesos estocásticos referidos a los aportes hidrológicos, la disponibilidad de las centrales, la generación de energía eólica y el precio de los combustibles existen otras fuentes de incertidumbre que afectan el valor obtenido al evaluar la aptitud de un genotipo.

Se optó por representar “La Demanda” y “El atraso de las inversiones” como procesos estocásticos “externos” a la simulación que determinan la “Suerte” de un genotipo dado al realizar la simulación. El procedimiento es el siguiente: Dado un genotipo, al momento de introducir su fenotipo en el archivo de simulación de SimSEE, se genera en forma aleatoria una proyección de la Demanda del sistema y un corrimiento en las fechas de entrada de los proyectos.

Para la Demanda del sistema se consideró un valor de 8846 GWh para el año 2009 y un crecimiento anual generado en forma aleatoria con una distribución uniforme en el intervalo: [2.04%, 4.04%]. El crecimiento anual es aleatorio y sorteado en forma independiente para cada año.

Para el atraso de las inversiones, se consideró que para cada entrada de proyecto (unidades del vector del genotipo), con probabilidad 50% el proyecto ingresa en el año estipulado en el genotipo y con probabilidad 50% se atrasa un año.

De esta forma, cuando evaluamos un genotipo, podrá tener la suerte de que le toque una demanda baja y los atrasos lo ayuden o lo hundan y entonces que parezca apto o inepto.

Que procesos estocásticos se modelan dentro de la simulación de SimSEE y forman parte de “una evaluación” de un genotipo y cuales de dejan afuera y forman parte de “La Suerte” de un individuo es parte del criterio de diseño de la solución del problema. Cuanto mayor sea la cantidad de procesos incorporados a la simulación de evaluación de la función de aptitud mayor será la cantidad de crónicas que necesitaremos evaluar para obtener un resultado significativo y mayor será el costo de evaluación de cada par (Genotipo;Suerte). Al dejar algunos procesos estocásticos fuera de la simulación, es posible administrar en parte el tiempo de cálculo evaluando con más detalle las genéticas que parecen más aptas.

En la solución implementada, el mismo genoma puede ser evaluado muchas veces con suertes diferentes (realizaciones de los procesos estocásticos: crecimiento de la demanda y atrasos de entrada de proyectos, en el ejemplo presentado). En la base de datos se va guardando para cada genoma evaluado, el promedio, el mínimo y el máximo del CAD y CADr5. En la función de aptitud en base a la cual actúa el principio de selección natural se considera el CAD promedio en el conjunto de suertes evaluadas (que a su vez es el promedio de las crónicas simuladas en cada suerte).

De esta forma se logra que genéticas que resulten muy exitosas por tener suerte en su primer evaluación, terminen siendo descartadas pues al aumentar su probabilidad de repetirse serán evaluadas nuevamente. Aquellos que son altamente no aptos serán descartados con pocas evaluaciones y tienen poca probabilidad de repetición. Este mecanismo de “la suerte” es una forma de administración del recurso de cálculo. Las genéticas que parecen más ganadoras se evaluarán más veces y solamente permanecen como más ganadoras si en el conjunto de evaluaciones demuestran serlo.

Este mecanismo de “la suerte” causa un efecto de tener un grupito de “ganadores” con suerte que es seguido por el grupo de las genéticas realmente probadas. En la fig. 3 se muestra el CAD de los 100 genotipos más aptos en el algoritmo luego de 414935 evaluaciones sobre una población de 404934 genotipos creados.




Fig. 3. El grupo de Los Afortunados.

En la Fig 3 se puede apreciar que el grupo de los “Los Afortunados” que con alta probabilidad serán desplazados al ser evaluado el mismo genotipo con otra suerte. Se puede observar que al momento de realizar la figura, el algoritmo ha llegado a un mínimo de CAD estable del entorno de los MUSD 5030.

### III. DETALLES DE LA IMPLEMENTACIÓN.

La implementación se basa en el programa “Colabora” realizado en lenguaje Pascal que realiza el siguiente bucle:

- 1) Seleccionar progenitores. Mediante el mecanismo de selección y consultando a la base de datos. Sin en la base de datos hay menos de dos genotipos, se crea un genotipo al azar con números enteros elegidos en forma aleatoria en los distintos casilleros del genotipo y se salta directamente al paso 4).
- 2) Crear nuevo genotipo por cruzamiento.
- 3) Con probabilidad 70% alterar el genotipo del paso 2 con el procedimiento de mutación.
- 4) Crear la sala SimSEE con el genotipo y agregarle la aleatoriedad de “la suerte”.
- 5) Llamar a SimSEE para obtener el valor del CAD y CAdR5 del genotipo creado.
- 6) Consultar a la base de datos si el genotipo ya existe, si es así actualizar el valor del promedio, máximo y mínimo del CAD y CAdR5 asociados. Sin no existe una evaluación anterior del genotipo, insertar un nuevo registro en la base de datos con los valores del CAD y CAdR5 obtenidos.
- 7) Repetir desde 1).

La base de datos donde se almacenan los resultados está definida en un servidor del Instituto de Ingeniería Eléctrica y accesible desde Internet. Esto permite ejecutar el programa Colabora en cualquier máquina con acceso a Internet con lo que es posible tener una red de computadoras participando de la optimización como se muestra en forma esquemática en la fig.4. En los resultados mostrados, se utilizó el CLUSTER de FING [2] y dos computadoras de escritorio. Participaron de la optimización en promedio 110 nodos de cálculo durante 14 días. El algoritmo está definido de forma tal que en cualquier momento se pueden agregar o quitar nodos de cálculo condición indispensable para utilizar durante tantos días este tipo de recurso ya sea por las eventuales fallas de equipos como por la necesidad de utilizarlos temporalmente para otras aplicaciones.

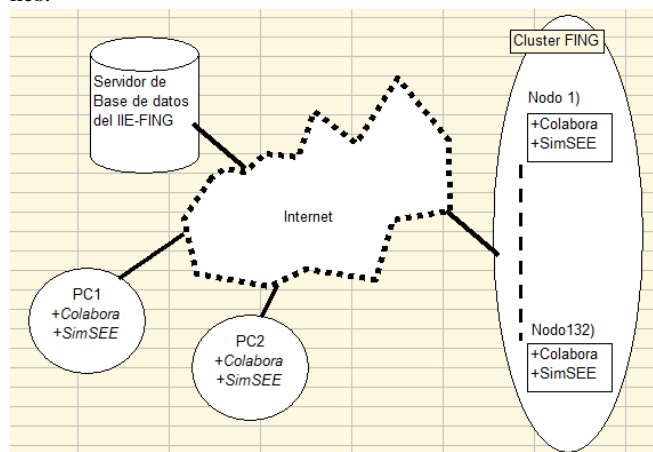


Fig.4. Configuración del Optimizador Genético Distribuido.

### IV. PRINCIPALES RESULTADOS.

El objetivo de este trabajo es mostrar la factibilidad aplicar algoritmos de optimización genética a la planificación de inversiones en generación y es en este sentido que analizaremos los resultados. No es la intención del trabajo hacer la planificación real de las inversiones por lo que los resultados no deben utilizarse como referencia en ese sentido.

En algoritmo se ejecuto por 14 días creando en total 404934 genotipos. En la Fig.5 se muestra el CAD de los primeros 100 y de los últimos 100 genotipos creados. Se puede apreciar que los primeros tienen un CAD superior que los últimos lo que muestra la mejora lograda por el algoritmo.




Fig.5. CAD de los Primeros y Últimos 100 Genotipos creados de una población de 404934.

Para tener una visión global de la mejora a medida que actúa la selección natural observar la Fig.6. En ella se muestra el CAD de los 404934 genotipos evaluados. Es de observar la variación importante de valores entre máximo y mínimo que muestra que el algoritmo es “tolerante” con los no aptos. Este es un aspecto que seguramente tenga origen en la forma de realizar el cruzamiento y que pueda buscarse una mejor forma de hacerlo.




Fig.6. CAD de los 404934, ordenados por orden de creación.

Para poder apreciar mejor la mejora se amplió la escala de forma de poder ver los mínimos de la Fig.6 mejor y se muestra la ampliación en la Fig.7.




Fig.7. Mínimos del CAD de los 404934 genotipos ordenados por orden de creación.

En la Fig.7 se aprecia que el óptimo mejora rápidamente en los primeros 1000 genotipos (flecha “a” en la figura) y se esta-

biliza entorno a los MUSD 5060. Por los 170000 genotipos creados (“b” en la figura) se produce una mejora asociada a una mutación que logró alcanzar una zona no explorada por sus antecesores y se vuelve a estabilizar los MUSD 5040. Hacia el final se producen algunas mejoras que seguramente no son estables y están asociada al “grupo de los Afortunados” antes mencionados.

La Fig.8 se muestra el Plan Óptimo obtenido como el promedio de los MW instalados por los genotipos de los 100 más exitosos luego de quitar del dicho grupo a los 11 más exitosos por considerar que el éxito de los mismos puede no ser estable.




Fig.8. Plan óptimo. Promedio de los más aptos.

## V. CONCLUSIÓN.

De los resultados obtenidos de la aplicación de un primer algoritmo de optimización genética del plan de inversiones los autores concluyen:

Es totalmente factible la utilización de algoritmos genéticos para este propósito. Se considera que el mecanismo de cruzamiento usado es “rústico” por no usar información adicional como por ejemplo las diferencias entre costos marginales del sistema y costos de inversión, información que se utiliza por los expertos para identificar en que años es oportuno agregar inversiones. Por consiguiente se estima que se debe poder mejorar mucho el mecanismo. Así y todo, el algoritmo funcionó y llegó a soluciones mejores de aquellas que en forma manual los autores habían logrado (usando más información). Por ejemplo, el optimizador logró “ver” algo que a simple vista no es apreciable y es que teniendo al inicio unos años de falta de equipamiento le es conveniente “sobre-equiparse” (respecto de la solución manual de los autores) en el primer año en que puede hacerlo. Al sobre-equiparse, puede ser más atrevido en el uso del lago en el año previo a la entrada del equipamiento. Por tanto, una vez más disponer de un simulador nos hace “ver” relaciones de un sistema que a simple vista permanecen ocultas. La dinámica del sistema impone relaciones de año a año que hace que las conclusiones que podríamos sacar mirando las variaciones de un solo año nos lleven a un sub-óptimo que es mejorado por el optimizador.



No cabe duda de la utilidad de disponer de un optimizador distribuido de funciones de alto costo de evaluación y que la búsqueda del óptimo tenga la posibilidad de explorar regiones que a priori los expertos podríamos haber ignorado.

## VI. TRABAJOS FUTUROS

Se propone hacer una librería de métodos de codificación de los genotipos y librerías para los mecanismos de selección, cruzamiento y mutación.

Se pondrá la plataforma Colabora+SimSEE disponible a grupos de estudiantes e investigadores para que todos puedan investigar diferentes formas de implementación de la codificación y las operaciones y de calibración de los mejores valores de los parámetros de los métodos permitiendo otra especie de optimización genética.

Se implementará un optimizador similar para la planificación de los mantenimientos del parque generador.

## VII. AGRADECIMIENTO

Un especial agradecimiento a Gabriel Usera (IMFIA-FING) por su apoyo en la utilización del CLUSTER de FING [2] gracias al cual fue posible realizar este trabajo en un tiempo razonable.

## VIII. REFERENCES

- [1] SimSEE: Simulador de Sistemas de Energía Eléctrica. Proyecto PDT 47/12. Gonzalo Casaravilla, Ruben Chaer, Pablo Alfaro. Technical Report 7, Universidad de la República (Uruguay). Facultad de Ingeniería. Instituto de Ingeniería Eléctrica, Number 7 - dec 2008.
- [2] CLUSTER-FING. Infraestructura de cómputo de alto desempeño perteneciente a la Facultad de Ingeniería. <http://www.fing.edu.uy/cluster/index.php>
- [3] Franz Rothlauf. Representations for Genetic and Evolutionary Algorithms. Editorial: Springer, 2002.
- [4] Ruben. Chaer y Raúl Zeballos, Modelo Simplificado de Central con Embalse con fines didácticos. IEEE LATIN AMERICA TRANSACTIONS, VOL. 4, NO. 3, MAY 2006.
- [5] U.S. Energy Administration Information, "International Energy Outlook - 2010," Office of Integrated Analysis and Forecasting, U.S. Department of Energy, Washington, DC 20585, Jul. 2010.
- [6] Simulación de granjas eólicas en el despacho óptimo del sistema hidro-térmico de generación de energía eléctrica del Uruguay. Ruben Chaer. Encuentro Latinoamericano de Economía de la Energía, ELAEE 2009. Santiago, Chile, page 1--13 - 21-24 mar. 2009.

## IX. BIOGRAFÍA



**Ruben Chaer** nació en Tacuarembó - Uruguay, en 1962. Recibió el grado de Ingeniero Electricista en 1990 y el grado de Magister en Ingeniería Eléctrica en 2009 de la Universidad de la República del Uruguay. Actualmente es Profesor Adjunto del Instituto de Ingeniería Eléctrica y asesor de presidencia de la empresa de energía eléctrica UTE en Uruguay.



**Gonzalo Casaravilla** nació en Montevideo - Uruguay, en 1963. Recibió el grado de Ingeniero Electricista en 1990, el grado de Magister en Ingeniería Eléctrica en 2000 y el grado de Dr. en Ingeniería Eléctrica en 2003 de la Facultad de Ingeniería del Uruguay. Actualmente es presidente de la empresa eléctrica UTE y Prof. Titular del Instituto de Ingeniería Eléctrica.